目 录

第一章 高维几何 1

1.1 在高维单位球中采样 1

1.2 高维单位球的体积 2

1.3 高维单位球的更多性质 5

1.3.1 体积趋于 0 5

1.3.2 体积集中在表面 5

1.3.3 体积集中在“赤道” 5

1.3.4 球上的点几乎两两正交 7

1.3.5 体积集中在中心的立方体内 7

1.4 随机投影，Johnson-Lindenstrauss 引理 8

第二章 奇异值分解 10

2.1 第一奇异值与第一奇异向量 10

2.2 奇异值分解 11

第三章 机器学习 14

3.1 感知机算法与核函数 14

3.2 泛化 15

3.2.1 基本情形 15

3.2.2 VC-Dimension 16

3.2.3 Growth Function 18

3.2.4 基于 VC-Dimension 的泛化界 18

3.3 从在线学习到博弈 19
3.3.1 在线学习 19
3.3.2 纳什均衡和 Minimax 定理 22
3.3.3 在线学习的感知机算法 23
3.4 Boosting 23

第四章 流和采样算法 25
4.1 流算法（Streaming） 25
4.1.1 加权采样 25
4.1.2 最常出现的元素 26
4.1.3 哈希与不同元素计数 26
4.1.4 频数的二阶矩 28
4.2 矩阵采样 29
4.2.1 Sampling 29
4.2.2 Sketching 30

第五章 随机图 32
5.1 “相变” 32

第一章 高维几何

1.1 在高维单位球中采样

我们用 $V(d,r)$ 表示 $\mathbb{R}^d$ 中的半径为 r 的球的体积，单位球的体积则简记作 $V(d)$。易见：

$$V(d,r) = r^d \cdot V(d)$$

在接下来的部分中，我们会多次遇到“从单位球中随机取一个点”的说法，所以我们需要弄清怎样在 d 维单位球中均匀地采样。先考虑如何在球的表面均匀采样：

Algorithm 1 单位球表面的采样

```
for i = 1 to d do
    独立地从标准高斯分布中采样 x_i ~ N(0,1)
end for
x = (x_1, ..., x_d)
x ← x / ||x||
return x
```

为什么这个算法是 work 的？回忆高斯分布的概率密度函数，有

$$p(x_i) \propto \exp\left(-\frac{1}{2}x_i^2\right)$$

$$p(x_1,\ldots,x_d) \propto \prod_{i=1}^{d} \exp\left(-\frac{1}{2}x_i^2\right) = \exp\left(-\frac{1}{2}\sum x_i^2\right) = \exp\left(-\frac{1}{2}\|x\|^2\right)$$

概率仅与 $\|x\|$ 有关，所以得到的点在球面上是均匀分布的。接下来，为了在整个球上采样，只需要把表面上的点“缩放”到整个球中即可。易知球表面积正比于 r^{d-1}，令 $p(r) = c \cdot r^{d-1}$，积分 $\int cr^{d-1} = 1 \Rightarrow c = d$，由此得到：

Algorithm 2 单位球中的采样

```
for i = 1 to d do
    从标准高斯分布中采样 x_i ~ N(0,1)
end for
x = (x_1, ..., x_d)/||x||
从 p(r) = d r^{d-1} 中采样 r
return rx
```

1.2 高维单位球的体积

本节来推导 $V(d)$ 的具体表达式。引入 $A(d,r)$ 和 $A(d)$ 来表示表面积。

引理 1.2.1 单位球体积和表面积有如下关系：

$$V(d) = \frac{A(d)}{d}$$

证明

$$V(d) = \int_0^1 A(d,r)\mathrm{d}r = A(d)\int_0^1 r^{d-1}\mathrm{d}r = \frac{A(d)}{d}$$

□

引理 1.2.2

$$\int_{-\infty}^{+\infty} \mathrm{e}^{-x^2} dx = \sqrt{\pi}$$

证明 首先有

$$\begin{aligned}\left(\int_{-\infty}^{+\infty} \mathrm{e}^{-x^2}\mathrm{d}x\right)^2 &= \left(\int_{-\infty}^{+\infty} \mathrm{e}^{-x^2}\mathrm{d}x\right)\left(\int_{-\infty}^{+\infty} \mathrm{e}^{-y^2}\mathrm{d}y\right) \\ &= \int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty} \mathrm{e}^{-(x^2+y^2)}\mathrm{d}x\mathrm{d}y\end{aligned}$$

从几何上看，整个体积可以当作对底面半径为 r，高为 e^{-r^2} 的圆柱面的累加：

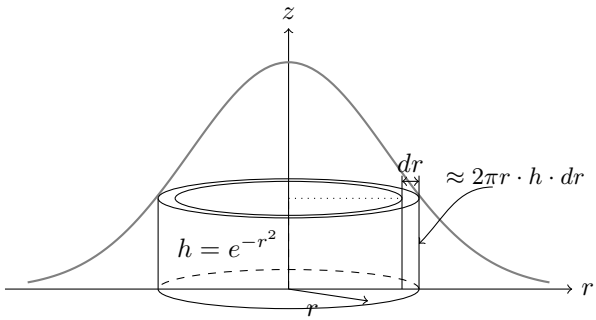

图 1–1: 高斯积分

于是

$$\begin{aligned}\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty} \mathrm{e}^{-(x^2+y^2)}\mathrm{d}x\mathrm{d}y &= \int_0^{+\infty} \mathrm{e}^{-r^2}\cdot 2\pi r\mathrm{d}r \\ &= \pi\int_0^{+\infty} \mathrm{e}^{-r^2}\mathrm{d}r^2 \\ &= \pi(-\mathrm{e}^{-r^2})\Big|_0^{+\infty} \\ &= \pi\end{aligned}$$

从而原积分等于 $\sqrt{\pi}$。 □

下面我们来计算 $V(d)$。方法是通过两种方式来计算积分：

$$\int_{-\infty}^{+\infty}\int_{-\infty}^{+\infty}\cdots\int_{-\infty}^{+\infty} \mathrm{e}^{-(x_1^2+\cdots+x_d^2)}\mathrm{d}x_1\ldots\mathrm{d}x_d$$

一方面，利用之前的结果，上面的积分正是

$$\left(\int_{-\infty}^{+\infty} \mathrm{e}^{-x^2}\mathrm{d}x\right)^d = \pi^{\frac{d}{2}}$$

另一方面，仍从几何上来看。令 $r^2 = x_1^2 + \cdots + x_d^2$，整个体积依然是底面半径为 r 的圆柱面的累加，只不过这里圆柱面的底面圆从 2 维变成了 d 维的。

$$\begin{aligned}&\int_{-\infty}^{+\infty}\cdots\int_{-\infty}^{+\infty} \mathrm{e}^{-(x_1^2+\cdots+x_d^2)}\mathrm{d}x_1\ldots\mathrm{d}x_d \\ =&\int_0^{+\infty} \mathrm{e}^{-r^2}\cdot A(d,r)\mathrm{d}r\end{aligned}$$

$$=A(d)\int_0^{+\infty}\mathrm{e}^{-r^2}r^{d-1}\mathrm{d}r$$

形如 $\int_0^{+\infty}x^n\mathrm{e}^{-x}\mathrm{d}x$ 的积分比较特别:

$$\begin{aligned}\int_0^{+\infty}x^n\mathrm{e}^{-x}\mathrm{d}x&=\int_0^{+\infty}x^n\mathrm{d}(-\mathrm{e}^{-x})\\&=-x^n\mathrm{e}^{-x}\Big|_0^{+\infty}+\int_0^{+\infty}\mathrm{e}^{-x}\mathrm{d}x^n\\&=n\int_0^{+\infty}x^{n-1}\mathrm{e}^{-x}\mathrm{d}x\end{aligned}$$

令 $\Gamma(t+1)=\int_0^{+\infty}x^t\mathrm{e}^{-x}\mathrm{d}x$，则 $\Gamma(t+1)=t\Gamma(t)$，因而它是阶乘的推广。回到上面，由于

$$\begin{aligned}\int_0^{+\infty}\mathrm{e}^{-r^2}r^{d-1}\mathrm{d}r&=\int_0^{+\infty}\mathrm{e}^{-r^2}(r^2)^{\frac{d-1}{2}}\mathrm{d}r\\&=\int_0^{+\infty}\mathrm{e}^{-t}t^{\frac{d-1}{2}}\frac{1}{2}t^{-\frac{1}{2}}\mathrm{d}t\\&=\frac{1}{2}\int_0^{+\infty}\mathrm{e}^{-t}t^{\frac{d}{2}-1}\mathrm{d}t\\&=\frac{1}{2}\Gamma\left(\frac{d}{2}\right)\end{aligned}$$

所以

$$\pi^{\frac{d}{2}}=A(d)\cdot\frac{1}{2}\Gamma\left(\frac{d}{2}\right)$$

由此得到结论:

定理 1.2.3 d 维单位球的表面积和体积公式:

$$A(d)=\frac{2\pi^{\frac{d}{2}}}{\Gamma(\frac{d}{2})}$$

$$V(d)=\frac{\pi^{\frac{d}{2}}}{\frac{d}{2}\Gamma(\frac{d}{2})}$$

1.3 高维单位球的更多性质

1.3.1 体积趋于 0

定理 1.3.1 d 维单位球的体积最终趋于 0，

$$\lim_{d\to\infty} V(d) = 0$$

证明 使用 Stirling 公式，略。 □

1.3.2 体积集中在表面

定理 1.3.2 设 S 为单位球，$(1-\epsilon)S = \{(1-\epsilon)x | x \in S\}$。则至少有 $1-\mathrm{e}^{-\epsilon d}$ 比例的体积分布在 $S \setminus (1-\epsilon)S$ （“球壳”）中。

证明

$$\frac{V((1-\epsilon)S)}{V(S)} = (1-\epsilon)^d \le \mathrm{e}^{-\epsilon d}$$

□

1.3.3 体积集中在“赤道”

定理 1.3.3 对 $c \ge 1, d \ge 3$，至少有 $1 - \frac{2}{c}\mathrm{e}^{-\frac{c^2}{2}}$ 比例的体积满足 $|x^{(1)}| \le \frac{c}{\sqrt{d-1}}$。

证明 记 S 为单位球。待定 $h \in (0,1)$，令

$$H = \{x \in S \mid x^{(1)} \ge 0\}$$

$$A = \{x \in S \mid x^{(1)} \ge h\}$$

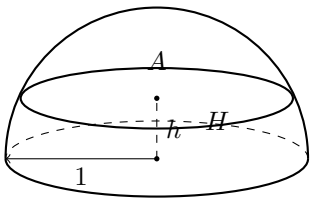

图 1–1: H 与 A

先来放缩 A 的体积:

$$V(A) = \int_h^1 V(d-1, \sqrt{1-x^2})\mathrm{d}x$$

$$
\begin{aligned}
&= V(d-1)\int_h^1 (1-x^2)^{\frac{d-1}{2}}\mathrm{d}x \\
&\le V(d-1)\int_h^1 \mathrm{e}^{-\frac{d-1}{2}x^2}\mathrm{d}x \\
&\le V(d-1)\int_h^{+\infty} \frac{x}{h}\mathrm{e}^{-\frac{d-1}{2}x^2}\mathrm{d}x \\
&= \frac{V(d-1)}{h}\int_h^{+\infty} \mathrm{e}^{-\frac{d-1}{2}x^2}\mathrm{d}\left(\frac{x^2}{2}\right) \\
&= \frac{V(d-1)}{h(d-1)}\mathrm{e}^{-\frac{d-1}{2}h^2}
\end{aligned}
$$

下面考虑 H 的体积（H 已经有了明确表达式为什么还要放缩？我们希望有一个包含 $V(d-1)$ 的界来和上面的消掉）。

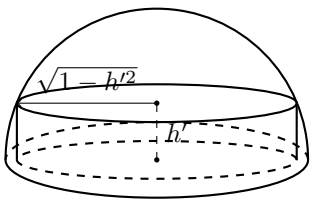

图 1–2: H

如图所示，$V(H)$ 一定大于等于高为 h' 的圆柱的体积（h' 也待定），这样就有

$$
\begin{aligned}
V(H) &\ge V(d-1,\sqrt{1-h'^2})\cdot h' = V(d-1)(1-h'^2)^{\frac{d-1}{2}}h' \\
&\ge V(d-1)\left(1-\frac{d-1}{2}h'^2\right)h'
\end{aligned}
$$

令 $h=\frac{c}{\sqrt{d-1}}$, $h'=\frac{1}{\sqrt{d-1}}$，则有：

$$
\begin{aligned}
V(A) &\le \frac{V(d-1)}{c\sqrt{d-1}}\mathrm{e}^{-\frac{c^2}{2}} \\
V(H) &\ge V(d-1)\cdot\left(1-\frac{1}{d-1}\cdot\frac{d-1}{2}\right)\cdot\frac{1}{\sqrt{d-1}} = \frac{V(d-1)}{2\sqrt{d-1}}
\end{aligned}
$$

综上可得：

$$
\frac{V(A)}{V(H)} \le \frac{2}{c}\mathrm{e}^{-\frac{c^2}{2}}
$$

□

1.3.4 球上的点几乎两两正交

定理 1.3.4 在单位球中随机取 n 个点 $x_1, \ldots, x_n$, 有 $1 - O(\frac{1}{n})$ 的概率使得

1. $\|x_i\| \geq 1 - \frac{2\ln n}{d} \quad \forall i.$
2. $|\langle x_i, x_j\rangle| \leq \frac{\sqrt{6\ln n}}{\sqrt{d-1}} \quad \forall i \neq j.$

证明 利用 Union Bound.

$$\begin{aligned}\Pr\left[\exists i, \|x_i\| < 1 - c\right] &\leq n \Pr\left[\|x_1\| < 1 - c\right] \\ &= n \cdot (1-c)^d < n\mathrm{e}^{-cd}\end{aligned}$$

只要使 $n\mathrm{e}^{-cd} \leq \frac{1}{n}$ 即可, 取 $c = \frac{2\ln n}{d}$.

对于第二个不等式, 将 x_1 旋转到 $(1, 0, \ldots, 0)$ 所在的方向, 则 $|\langle x_1, x_j\rangle| \leq |x_j^{(1)}|$. 利用刚刚的结果,

$$\begin{aligned}\therefore \Pr\left[\exists i \neq j, |\langle x_i, x_j\rangle| > \frac{c}{\sqrt{d-1}}\right] &\leq n^2 \Pr\left[|\langle x_1, x_2\rangle| > \frac{c}{\sqrt{d-1}}\right] \\ &\leq n^2 \Pr\left[|x_1^{(1)}| > \frac{c}{\sqrt{d-1}}\right] \\ &\leq n^2 \cdot \frac{2}{c}\mathrm{e}^{-\frac{c^2}{2}} \\ &\leq n^2 \mathrm{e}^{-\frac{c^2}{2}}\end{aligned}$$

只要让 $n^2\mathrm{e}^{-\frac{c^2}{2}} \leq \frac{1}{n}$, 即 $\mathrm{e}^{-\frac{c^2}{2}} \leq \frac{1}{n^3}$. 取 $c = \sqrt{6\ln n}$ 即可. □

1.3.5 体积集中在中心的立方体内

定理 1.3.5 单位球至少一半的体积集中在中心在原点的边长 $\frac{4\sqrt{\ln d}}{\sqrt{d-1}}$ 的正方体内部。

证明

$$\Pr\left[\exists i, |x^{(i)}| > \frac{c}{\sqrt{d-1}}\right] \leq d \cdot \frac{2}{c}\mathrm{e}^{-\frac{c^2}{2}}$$

取 $c = 2\sqrt{\ln d}$, 则上界为 $d \cdot \frac{1}{\sqrt{\ln d}} \cdot \frac{1}{d^2} < \frac{1}{d} < \frac{1}{2}$。 □

这也为 $V(d) \to 0$ 提供了另一种证明。

注: 看上去与球的体积集中在表面矛盾? 实际上这个立方体在 d 较大的时候并不是完全位于球的内部的, 会伸出来很多 “刺”, 类似于一个 “海胆”, 参见书上的这幅图:

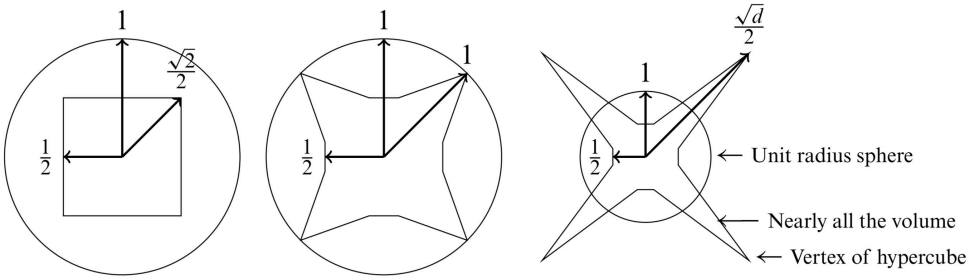

图 1–3: 2, 4, d 维的球面与立方体的示意图

1.4 随机投影，Johnson-Lindenstrauss 引理

先简单引入一个工具：

定理 1.4.1 对任意正整数 d，独立地从标准高斯中采样 $x = (x_1, \ldots, x_d)$，则存在正常数 c，使得对 $\beta \le \sqrt{d}$，至少有 $1 - 3\mathrm{e}^{-c\beta^2}$ 的概率使

$$\|x\| \in [\sqrt{d} - \beta, \sqrt{d} + \beta].$$

这个定理称为“高斯圆环定理”，此处不证。其实很符合直觉：$\mathbb{E}[\|x\|^2] = \mathbb{E}[x_1^2 + \cdots + x_d^2] = d\mathbb{E}[x_1^2] = d$，故 x 大概率分布在半径 $\sqrt{d}$ 附近的“圆环”中。

接下来我们关心这样一件事情，对于 $k \ll d$，给定 $\mathbb{R}^d$ 中的 n 个点 $v_1, \ldots, v_n$，能否找到一个投影 $f : \mathbb{R}^d \longrightarrow \mathbb{R}^k$ 使得在降维的同时尽量保持这 n 个点间的距离？也即对 $\epsilon \in (0, 1)$，$\forall i, j$：

$$(1 - \epsilon)\|v_i - v_j\| \le \|f(v_i) - f(v_j)\| \le (1 + \epsilon)\|v_i - v_j\|?$$

为了解决这件事，我们需要使用所谓的**概率方法**：要证明存在满足性质 $P(x)$ 的对象 x，只要证明以某种方式随机取 x，$\Pr[P(x)] > 0$ 即可。

如何来构造这种随机？我们利用标准高斯分布，随机选取 $u_1, \ldots, u_k \in \mathbb{R}^d$ i.i.d $\sim N(0, 1)$。定义 $f : \mathbb{R}^d \longrightarrow \mathbb{R}^k$，

$$v \mapsto (\langle v, u_1 \rangle, \ldots, \langle v, u_k \rangle)$$

我们可以证明，这样的 f 大概率能把距离保持地很好：

定理 1.4.2 对于 $0 < \epsilon < 1$，$\forall n \in \mathbb{N}^*$，$\exists c > 0$，当 $k \ge \frac{3}{c\epsilon^2} \ln n$ 时，对 $\mathbb{R}^d$ 中任何 n 个

点，如上定义的 f 有至少 $1-\frac{3}{2n}$ 的概率使得 $\forall i,j$

$$(1-\epsilon)\sqrt{k}\|v_i-v_j\| \le \|f(v_i)-f(v_j)\| \le (1+\epsilon)\sqrt{k}\|v_i-v_j\|$$

证明 f 是线性映射，$f(v_i)-f(v_j)=f(v_i-v_j)$。实际上只需要考虑对 $\mathbb{R}^d$ 中的 n^2 个点，

$$\|f(v)\| \in [\|v\|(1-\epsilon), \|v\|(1+\epsilon)]$$

对于 $f(v)$ 的分量 $\langle v,u_i\rangle = \sum v^{(j)}u_i^{(j)}$，由于 u 的每个坐标分量均独立地服从高斯分布，故 $\langle v,u_i\rangle$ 也服从高斯分布，并且可以计算出

$$\begin{aligned}\mathbb{E}[\langle v,u_i\rangle] &= 0\\ \mathrm{Var}[\langle v,u_i\rangle] &= \sum (v^{(j)})^2 = \|v\|^2\end{aligned}$$

即 $\langle v,u_i\rangle \sim N(0,\|v\|^2)$。

令 $v \leftarrow \frac{v}{\|v\|}$，不妨设 $\|v\|=1$。此时我们已经知道 $\|f(v)\| \approx \sqrt{k}$。在高斯圆环定理中取 $\beta=\sqrt{k}\epsilon$，则 $\exists c>0$，至少有 $1-3\mathrm{e}^{-ck\epsilon^2}$ 的概率使

$$\|f(v)\| \in [\sqrt{k}(1-\epsilon), \sqrt{k}(1+\epsilon)]$$

利用 Union Bound，只需

$$\frac{n^2}{2}\cdot 3\mathrm{e}^{-ck\epsilon^2} < \frac{3}{2n}$$

$k > \frac{3}{c\epsilon^2}\ln n$ 已足够。 □

修改 $f: v \mapsto \frac{1}{\sqrt{k}}(\dots)$，这样的 f 就符合了我们最开始的动机。

第二章 奇异值分解

2.1 第一奇异值与第一奇异向量

奇异值分解 (Singular Value Decomposition, SVD) 始于研究一组向量的“最佳拟合直线”。例如，有若干向量 $a_1, \ldots, a_n \in \mathbb{R}^d$，我们希望找到一个方向向量 v，来最小化所有向量与 v 所确定的直线的距离的平方和。由勾股定理，这就等价于最大化所有向量在这条直线上的投影的平方和。将 $a_1, \ldots, a_n$ 作为行向量组成矩阵 A，那么：

$$\|Av\|^2 = \left\| \begin{pmatrix} a_1^\top \\ \vdots \\ a_n^\top \end{pmatrix} v \right\|^2 = \sum |a_i^\top v|^2 = \sum \mathrm{proj}_i^2$$

因此，上述目标就等价于：

$$\max_{\|v\|=1} \|Av\|$$

我们将 $\sigma_1 = \max_{\|v\|=1} \|Av\|$ 定义为**第一奇异值**，同时将对应的 v (记为 v_1) 称为**第一奇异向量**（第一右奇异向量），同时记 u_1 为 Av_1 方向的单位向量，即 $Av_1 = \sigma_1 u_1$（u_1 也被称为第一左奇异向量）。

引入 Frobenius 范数：

$$\|A\|_F = \sqrt{\sum_i \sum_j |a_{ij}|^2}$$

我们还可以从另一个角度来理解。令 $A_1 = Av_1 v_1^\top$，我们断言 A_1 是在 Frobenius 范数

的意义下对矩阵的 A 的秩 1 最佳逼近：

命题 2.1.1 对任意秩为 1 的矩阵 B，有：

$$\|A - A_1\|_F \leq \|A - B\|_F$$

证明 证明分两个步骤。首先，既然 B 是秩为 1 的，它的行向量必然共线，设方向向量为 v。由于

$$\|A - B\|_F^2 = \left\| \begin{pmatrix} a_1^\top - b_1^\top \\ \vdots \\ a_n^\top - b_n^\top \end{pmatrix} \right\|_F^2 = \sum \|a_i - b_i\|^2$$

要想让这个数最小，b_i 一定是 a_i 在方向 v 上的投影。在此基础上，我们再考虑什么样的 v 能够取得最小值，而这正是我们一开始所寻找的“最佳拟合直线”。 □

2.2 奇异值分解

接下来，我们可以定义第二奇异值和第二奇异向量，也就是寻找“最佳拟合平面”（或者秩 2 最佳逼近）。设平面由正交的单位向量 w_1, w_2 确定，则对于向量 a：

$$\|\mathrm{proj}(a)\|^2 = \langle a, w_1 \rangle^2 + \langle a, w_2 \rangle^2$$

同样把 $a_1, \ldots, a_n$ 作为行向量写成矩阵，则：

$$\sum \|\mathrm{proj}(a_i)\|^2 = \sum \langle a_i, w_1 \rangle^2 + \sum \langle a_i, w_2 \rangle^2 = \|Aw_1\|^2 + \|Aw_2\|^2$$

所以我们的目标就是：

$$\max_{\substack{\|w_1\| = \|w_2\| = 1 \\ w_1 \perp w_2}} \left(\|Aw_1\|^2 + \|Aw_2\|^2 \right)$$

如何找这样的 w_1, w_2？尝试如下的“贪心算法”：

Algorithm 3 最佳拟合平面

1: $v_1 = \arg\max_{\|v\|=1} \|Av\|$
2: $v_2 = \arg\max_{\|v\|=1, v \perp v_1} \|Av\|$

也就是在第一奇异向量 v_1 的基础上，在与之正交的向量中继续确定 v_2。下面来证明这个算法的正确性。

证明 任取正交的单位向量 w_1，w_2。首先，永远有 $\|Av_1\| \geq \|Aw_1\|$。注意到 $\|Aw_1\|^2 + \|Aw_2\|^2$ 仅仅由 w_1 和 w_2 所确定的平面决定，与坐标轴的摆放方式无关，我们可以旋转 w_1 和 w_2 而不改变 $\|Aw_1\|^2 + \|Aw_2\|^2$。因此，不妨将 w_2 取作该平面内与 v_1 正交的向量，这样就有：

$$\|Av_2\| \geq \|Aw_2\|$$

从而：

$$\|Av_1\|^2 + \|Av_2\|^2 \geq \|Aw_1\|^2 + \|Aw_2\|^2$$

□

v_2 便是第二奇异向量，$\sigma_2 = \|Av_2\|$ 便是第二奇异值。

特别地，有一个不太平凡的点：

命题 2.2.1 $Av_1 \perp Av_2$。

证明 构造函数 $f(\theta) = \|A(\cos\theta v_1 + \sin\theta v_2)\|^2$，$\theta \in [-\pi, \pi)$。展开可得：

$$\begin{aligned} f(\theta) &= \|\cos\theta Av_1 + \sin\theta Av_2\|^2 \\ &= \cos^2\theta\|Av_1\|^2 + \sin^2\theta\|Av_2\|^2 + \sin(2\theta)\langle Av_1, Av_2\rangle \end{aligned}$$

求导：

$$f'(\theta) = 2\sin\theta\cos\theta(\|Av_2\|^2 - \|Av_1\|^2) + 2\cos 2\theta\langle Av_1, Av_2\rangle$$

$$f'(0) = 2\langle Av_1, Av_2\rangle$$

若 Av_1 与 Av_2 不垂直，则 $f'(0) \neq 0$。这意味着 $\exists\theta \neq 0$ 使：

$$\|A(\cos\theta v_1 + \sin\theta v_2)\| > \|Av_1\|$$

这与 v_1 的定义（最大化 $\|Av\|$）矛盾！ □

接续以上的过程，最终得到一列正交单位向量 $v_1, \ldots, v_d$，且 $Av_1, \ldots, Av_d$ 同样两两正交。令 $Av_i = \sigma_i u_i$ (u_i 为单位向量)，那么：

$$A = \sum Av_i v_i^\top = \sum \sigma_i u_i v_i^\top = U\Sigma V^\top$$

其中

$$U = (u_1|\ldots|u_d), \quad V = (v_1|\ldots|v_d), \quad \Sigma = \mathrm{diag}(\sigma_1, \ldots, \sigma_d)$$

这就是 A 的**奇异值分解**。特别地，

$$\|A\|_F^2 = \sum \sigma_i^2$$

如果截取前 k 个奇异值/奇异向量，仿照上文的推导，这就是“最佳拟合 k 维子空间”或者“秩 k 最佳逼近”。

最后的一点问题是，我们应当如何计算奇异值分解？由 $Av_i = \sigma_i u_i$，得 $u_i^\top A v_i = \sigma_i$，即 $u_i^\top A = \sigma_i v_i^\top$，也即 $A^\top u_i = \sigma_i v_i$。进而：

$$A^\top A v_i = A^\top(\sigma_i u_i) = \sigma_i(A^\top u_i) = \sigma_i(\sigma_i v_i) = \sigma_i^2 v_i$$

所以 v_i 正是 $A^\top A$ 的特征向量，σ_i^2 就是对应的特征值。我们就可以通过计算特征值来计算 SVD。对于计算机来说，可以使用 Power Method，随机取 $v = \sum c_i v_i$，计算 $(A^\top A)^k v = \sum \sigma_i^{2k} c_i v_i \approx \sigma_1^{2k} c_1 v_1$，这里不再详述。

第三章 机器学习

3.1 感知机算法与核函数

给定样本点 (x_i, y_i)，其中 $x_i \in \mathbb{R}^d$，$y_i \in \{1, -1\}$。考虑线性函数 $h(x) = \langle w, x\rangle + b$，我们希望以 $\mathrm{sign}(h(x))$ 为依据来对样本点进行分类。如果令 $\tilde{x} \leftarrow (x, 1)^\top$，$\tilde{w} \leftarrow (w, b)^\top$，那么 $h(x) = \langle \tilde{w}, \tilde{x}\rangle$，就可以把 b 合并进内积，以下只用考虑 $h(x) = \langle w, x\rangle$ 的情形。

感知机算法是最基本的一种学习算法，大体流程如下：

Algorithm 4 感知机算法

```
初始化 w = 0
loop
    if ∃i, y_i⟨w, x_i⟩ ≤ 0 then
        w ← w + y_i x_i
    else
        break
    end if
end loop
return w
```

$y_i\langle w, x_i\rangle \le 0$ 也就是相应的点被错误分类，一旦错误分类就增大它的权重。虽然算法很简单，但我们可以断言，只要数据是线性可分的（存在 w^* 使得 $\forall i$，$y_i\langle w^*, x_i\rangle \ge 1$），那么算法一定能收敛。

定理 3.1.1 若 $\exists w^*$ 使 $\forall i, y_i\langle x_i, w^*\rangle \ge 1$，那么算法在有限步内收敛。

证明 设更新 t 次后的结果为 w_t，也即 $w_{t+1} = w_t + y_i x_i$，其中 $y_i\langle w_t, x_i\rangle \le 0$。

一方面，

$$\begin{aligned}\langle w_{t+1}, w^*\rangle &= \langle w_t + y_i x_i, w^*\rangle \\ &= \langle w_t, w^*\rangle + y_i\langle x_i, w^*\rangle \\ &\geq \langle w_t, w^*\rangle + 1\end{aligned}$$

于是

$$\langle w_t, w^*\rangle \geq t$$

另一方面，假设 $\|x_i\| \leq r, \forall i$，那么

$$\begin{aligned}\|w_{t+1}\|^2 &= \|w_t + y_i x_i\|^2 \\ &= \|w_t\|^2 + 2y_i\langle w_t, x_i\rangle + \|y_i x_i\|^2 \\ &\leq \|w_t\|^2 + r^2 \quad (\text{因为} y_i\langle w_t, x_i\rangle \leq 0)\end{aligned}$$

所以

$$\|w_t\|^2 \leq tr^2 \implies \|w_t\| \leq r\sqrt{t}$$

综合上述两点：

$$t \leq \langle w_t, w^*\rangle \leq \|w_t\|\|w^*\| \leq r\sqrt{t}\|w^*\|$$

$\therefore$ 有限步内算法一定停止。 □

如果数据是线性不可分的，那么可以使用**核函数**，也就是把内积 $\langle x_i, x_j\rangle = x_i^\top x_j$ 换成 $k(x_i, x_j) = \phi(x_i)^\top\phi(x_j)$，通过 ϕ 把数据点映射到高维的空间中，这里不详细展开。

3.2 泛化

3.2.1 基本情形

先来引入一些基本符号：

- $\mathcal{D}$：数据的真实分布。
- S：从 $\mathcal{D}$ 采样得到的训练集。
- c^*: target concept，也就是说 $\forall x, c^*(x)$ 是 ground truth label。
- $h \in \mathcal{H}$: hypothesis，也就是分类器。
- 真实误差 True Error: $\mathrm{Err}_{\mathcal{D}}(h) = \Pr_{x\sim\mathcal{D}}[h(x) \neq c^*(x)]$。
- 训练误差 Training Error: $\mathrm{Err}_S(h)$。

我们关心我们的模型的**泛化 (Generalization)** 性能，换言之我们希望如果

$\mathrm{Err}_S(h)=0$，那么 $\mathrm{Err}_{\mathcal{D}}(h)$ 也应当很小。如果 $\mathcal{H}$ 是有限集，那么从 Union Bound 出发，我们就可以得到一个基本的估计：

定理 3.2.1 若 $|S|>\frac{1}{\epsilon}\log\frac{|\mathcal{H}|}{\delta}$，则至少有 $1-\delta$ 的概率使得

$$\forall h\in\mathcal{H},\mathrm{Err}_{\mathcal{D}}(h)\geq\epsilon\implies Err_S(h)>0$$

(等价地说：$Err_S(h)=0\implies\mathrm{Err}_{\mathcal{D}}(h)<\epsilon$)

证明 记 $n=|S|$,

$$\begin{aligned}\Pr[\exists h\in\mathcal{H},\mathrm{Err}_{\mathcal{D}}(h)\geq\epsilon\text{ but }\mathrm{Err}_S(h)=0]&\leq|\mathcal{H}|\cdot(1-\epsilon)^n\\&\leq|\mathcal{H}|\cdot\mathrm{e}^{-\epsilon n}\end{aligned}$$

令 $|\mathcal{H}|\cdot\mathrm{e}^{-\epsilon n}<\delta$ 整理得证. □

一般地可以证明：当 $|S|>\frac{1}{2\epsilon^2}(\log|\mathcal{H}|+\log\frac{2}{\delta})$ 时，至少有 $1-\delta$ 的概率，

$$|\mathrm{Err}_{\mathcal{D}}(h)-\mathrm{Err}_S(h)|<\epsilon$$

课上没讲这个证明，实际是用 Chernoff Bound:

$$|\mathrm{Err}_{\mathcal{D}}(h)-\mathrm{Err}_S(h)|\leq2|\mathcal{H}|\cdot\mathrm{e}^{-2n\epsilon^2}$$

注：上面的定理一定程度上支持了 Occam 剃刀原理。改写一下结果相当于说至少有 $1-\delta$ 的概率，$\mathrm{Err}_S(h)=0\implies$

$$\mathrm{Err}_{\mathcal{D}}(h)<\frac{\log|\mathcal{H}|+\log(1/\delta)}{|S|}$$

所以对于越简单的规则，$|\mathcal{H}|$ 越小，上面的 bound 就越紧（假设 $\mathcal{H}$ 中的规则以 b bit 来描述，那么 $|\mathcal{H}|\leq2^b$，代入上式 $\mathrm{Err}\lesssim b/|S|$）。

3.2.2 VC-Dimension

当 $|\mathcal{H}|=\infty$ 时，上面的定理不再适用。关键是，虽然我们有无穷多 h，但是很多 h 实际分类效果没有区别，比如说对于两条不同的直线，虽然方程不同但是可能把点分成了相同的部分。我们需要引入一个量来衡量 $\mathcal{H}$ 中本质上有多少不同的分类器，这就导向了 **VC 维度**的概念。

注：本节中我们把 $\mathcal{H}$ 视为一个 Set System，也就是若干集合 h 的集合，每个 $h\in\mathcal{H}$ 相当于上文记号的 $\{x\in X\mid h(x)=1\}$。

定义 3.2.2 对于集合 X 和 hypothesis class $\mathcal{H}$，取 $A\subset X$。若 $\forall S\subset A,\exists h\in\mathcal{H}$ s.t. $S=h\cap A$ (此时也称 S can be expressed by h)，则称 A is shattered by $(X,\mathcal{H})$。

换言之，如果一个样本集 A 能够被 $\mathcal{H}$ 分类成所有可能的样子，就说 A 能够被 shatter（中文意思是“打散”）。

定义 3.2.3 给定集合 X 和 hypothesis class $\mathcal{H}$，如果

- $\exists A \subset X, |A| = d, A$ 能够被 shatter。
- $\forall A \subset X, |A| = d+1, A$ 不能被 shatter。

就称 $(X, \mathcal{H})$ 的 VC-Dimension 为 d。如果第二点的 d 不存在，就记 $(X, \mathcal{H})$ 的 VC-Dimension 为 $+\infty$。

也即 VC-Dimension 表示 $\mathcal{H}$ 在 X 中最大能打散多大的集合。

例 3.2.4 一些简单的 VC-Dimension。

- $X = \mathbb{R}, \mathcal{H} = \{[a, b]\}, VC = 2.$
- $X = \mathbb{R}, \mathcal{H} = \{[a, b] \cup [c, d]\}, VC = 4.$
- $X = \mathbb{R}, \mathcal{H} = \{\text{有限集}\}, VC = +\infty.$
- $X = \mathbb{R}^2, \mathcal{H} = \{\text{边平行于坐标轴的矩形}\}, VC = 4.$
- $X = \mathbb{R}^2, \mathcal{H} = \{\text{凸多边形}\}, VC = +\infty.$

下面是个不是太平凡的例子。

定理 3.2.5 $X = \mathbb{R}^d, \mathcal{H} = \{d\text{维半平面}\}$, 则 $VC = d + 1.$

证明 先考虑原点 + 坐标轴正方向上单位长度的点，共 $d+1$ 个，显然可以 shatter，故 $VC \geq d+1$。

任取 $d+2$ 个点 $x_i \in \mathbb{R}^d$，加上一个维度的 1，得到 $p_i = (x_i^{(1)}, \ldots, x_i^{(d)}, 1)^\top$，此时 $p_i \in \mathbb{R}^{d+1}$。由于 p_i 共有 $d+2$ 个，它们必然线性相关，即存在不全为 0 的 $c_i \in \mathbb{R}$，使得

$$\sum c_i p_i = 0$$

特别地，从最后一个维度来看，$\sum c_i = 0$，故 c_i 有正有负。此时

$$\sum_{c_i \geq 0} c_i p_i = \sum_{c_i \leq 0} (-c_i) p_i$$

记 $M = \sum_{c_i \geq 0} c_i$，有

$$\sum_{c_i \geq 0} \frac{c_i}{M} \cdot p_i = \sum_{c_i \leq 0} \frac{|c_i|}{M} p_i$$

这意味着两部分的凸包是有交集的，必然线性不可分。于是 $VC = d + 1$。 □

推论 3.2.6 $X = \mathbb{R}^d, \mathcal{H} = \{d\text{维球}\}, VC = d + 1$，实际上和线性分类器并无区别。

3.2.3 Growth Function

定义 3.2.7 $\pi_{\mathcal{H}}(n) := \max_{|S|=n} |\{h \cap S \mid h \in \mathcal{H}\}|$ 称为 Growth Function。

Growth Function 反映的是 $\mathcal{H}$ 的“表现力”，显然总有 $\pi_{\mathcal{H}}(n) \le 2^n$。VC-Dimension 正是最大的满足 $\pi_{\mathcal{H}}(n) = 2^n$ 的 n。当 n 大于 VC-Dimension 时，下面的定理指出 $\pi_{\mathcal{H}}(n) = O(n^d)$：

定理 3.2.8 $VC(X, \mathcal{H}) = d$，则

$$\pi_{\mathcal{H}}(n) \le \binom{n}{\le d} = \binom{n}{0} + \cdots + \binom{n}{d}$$

不难证明 $\binom{n}{\le d} \le n^d + 1$。

定理 3.2.9 $\pi_{\mathcal{H}_1 \cap \mathcal{H}_2}(n) \le \pi_{\mathcal{H}_1}(n) \cdot \pi_{\mathcal{H}_2}(n)$.

证明 $h \cap S = (h_1 \cap S) \cap (h_2 \cap S)$，由此确定了满射 $\{h \cap S \mid h \in \mathcal{H}_1\} \times \{h \cap S \mid h \in \mathcal{H}_2\} \to \{h \cap S \mid h \in \mathcal{H}\}$。注：实际上 $\cap$ 可以是任意的组合方式。$\cap$ 可以看作对 h_1 和 h_2 的输出过了一下与门，可以推广到其他的布尔函数。 □

3.2.4 基于 VC-Dimension 的泛化界

定理 3.2.10 当 $|S| = n \ge \frac{4}{\epsilon}\left(\log(2\pi_{\mathcal{H}}(2n)) + \log\frac{1}{\delta}\right)$ 时，至少有 $1-\delta$ 的概率使得

$$\forall h \in \mathcal{H}, \mathrm{Err}_S(h) = 0 \implies \mathrm{Err}_{\mathcal{D}}(h) < \epsilon$$

证明 再从分布 $\mathcal{D}$ 中 sample S', $|S'| = |S| = n$。定义

- 事件 A: $\exists h \in \mathcal{H}, \mathrm{Err}_S(h) = 0$ 但 $\mathrm{Err}_{\mathcal{D}}(h) > \epsilon$。
- 事件 B: $\exists h \in \mathcal{H}, \mathrm{Err}_S(h) = 0$ 但 $\mathrm{Err}_{S'}(h) > \frac{\epsilon}{2}$。

记 S' 中的样本为 $X_1 \ldots X_n$，在事件 A 的条件下, $\mathbb{E}[X_i] > \epsilon, \mathrm{Var}(X_i) \le \epsilon$，则

$$\begin{aligned}
\Pr[\neg B \mid A] &= \Pr\left[\sum X_i \le \frac{1}{2}n\epsilon\right] \\
&\le \Pr\left[\left|\sum X_i - \mathbb{E}\left[\sum X_i\right]\right| \ge \frac{n\epsilon}{2}\right] \\
&\le \mathrm{Var}\left(\sum X_i\right) \cdot \left(\frac{2}{n\epsilon}\right)^2 \le \frac{4}{n\epsilon}
\end{aligned}$$

只要 $n > \frac{8}{\epsilon}$，就有 $\Pr[B \mid A] \ge \frac{1}{2}$, 此时 $\Pr[B] \ge \Pr[A]\Pr[B \mid A] \ge \frac{1}{2}\Pr[A]$。

因此，要让 $\Pr[A] < \delta$，只要 $\Pr[B] < \frac{1}{2}\delta$ 即可。

换一种采样 S 的方式：先采样 $2n$ 个点，将其随机分两半，一部分是 S，另一部分是 S'，这种采样方式和之前等价。对于某个确定的 $h \in \mathcal{H}$，若 $\mathrm{Err}_{S \cup S'}(h) \le \frac{\epsilon}{4}$ 则

$\Pr[B]=0$，因此只用考虑 $\mathrm{Err}_{S\cup S'}(h)>\frac{\epsilon}{4}$ 的情形，此时 $S\cup S'$ 的 $2n$ 个点中至少有 $2n\cdot\frac{\epsilon}{4}=\frac{\epsilon n}{2}$ 个“坏点”，这些“坏点”全在 S' 中的概率：

$$p\le\frac{2n-\frac{1}{2}\epsilon n}{2n}\cdot\frac{2n-1-\frac{1}{2}\epsilon n}{2n-1}\cdots\frac{n+1-\frac{\epsilon n}{2}}{n+1}\le\left(1-\frac{\epsilon}{4}\right)^n$$

由于 $|\{h\cap(S\cup S')\mid h\in\mathcal{H}\}|\le\pi_{\mathcal{H}}(2n)$，由 Union Bound 得

$$\Pr[B]\le\pi_{\mathcal{H}}(2n)\cdot\left(1-\frac{\epsilon}{4}\right)^n\le\pi_{\mathcal{H}}(2n)\mathrm{e}^{-\frac{\epsilon n}{4}}$$

令 $\pi_{\mathcal{H}}(2n)\mathrm{e}^{-\frac{\epsilon n}{4}}\le\frac{\delta}{2}$，解得

$$n\ge\frac{4}{\epsilon}\left(\log(2\pi_{\mathcal{H}}(2n))+\log\frac{2}{\delta}\right)$$

注：书上的 Bound 是 $\frac{2}{\epsilon}(\ldots)$。它是考虑 k 个“坏点”全分到 S' 的概率不超过 $(1/2)^k$。这里使用的证明技巧被称为“double sampling”，把一个无穷大的采样空间巧妙地转化成了有限的。 □

推论 3.2.11 $|S|=O\left(\frac{1}{\epsilon}(VC(\mathcal{H})\log\frac{1}{\epsilon}+\log\frac{1}{\delta})\right)$ 时，至少有 $1-\delta$ 的概率，$\forall h\in\mathcal{H},\mathrm{Err}_S(h)=0\implies\mathrm{Err}_{\mathcal{D}}(h)<\epsilon$。

证明 利用 $\pi_{\mathcal{H}}(n)=O(n^d)$ 和 $n=a\log n\Rightarrow n\ge ca\log a$ 在两边消去 n。 □

3.3 从在线学习到博弈

3.3.1 在线学习

我们最初的情景是，有几位专家为我们提供建议，我们需要作出决策。已知几位专家在前 t 天的建议，前 t 天的结果，和几位专家在 $t+1$ 天的建议，需要一个算法来输出 $t+1$ 天的决策。

如果存在 perfect expert（不会犯错），那么我们可以采用下面的算法：

Algorithm 5 majority 算法

```
for t = 1, 2, ... do
    在前 t − 1 天全对的专家中取多数
end for
```

定理 3.3.1 有 n 位专家，以上算法犯错误次数不超过 $\log n$。

证明 每次犯错至少有一半的专家被排除。 □

如果 perfect expert 不存在？我们引入权重：

Algorithm 6 weighted majority 算法

```
初始化所有专家权重为 1
loop
    选择权重之和最大的建议
    如果犯错，权重 ×1/2
end loop
```

定理 3.3.2 设有 n 位专家，算法的犯错误次数为 M，而犯错误最少的专家的犯错次数为 m，上面的算法可以保证

$$M \leq \frac{\ln n + m \ln 2}{\ln 4/3}$$

证明 每次犯错意味着权重之和过半的建议是错的。因此至少一半的权重被惩罚，总权重至少减少 25%。M 次犯错后总权重 $\leq n \cdot (3/4)^M$。

同时总权重 $\geq$ 当前最好的那位专家的权重 $= (1/2)^m$。

$\therefore n(3/4)^M \geq (1/2)^m$ 整理即可。

注：1/2 可换成 $1-\epsilon$，此时解不等式 $n(1-\frac{\epsilon}{2})^M \geq (1-\epsilon)^m$ 即可。 □

另一种策略：

Algorithm 7 randomized weighted majority 算法

```
初始化所有专家权重为 1
loop
    将权重之和作为概率来选取建议
    如果犯错，权重 ×(1 − ϵ)
end loop
```

定理 3.3.3 设有 n 位专家，算法的期望犯错误次数为 M，而犯错误最少的专家的期望犯错次数为 m，上面的算法可以保证

$$M \leq \frac{\ln n - m \ln(1-\epsilon)}{\epsilon} \approx (1+\frac{\epsilon}{2})m + \frac{1}{\epsilon}\ln n$$

证明 第 t 天犯错的概率为为

$$F_t = \frac{W_{True}}{W_{True} + W_{False}}$$

更新前后的期望权重和之比为

$$\frac{W_{True}+(1-\epsilon)W_{False}}{W_{True}+W_{False}}=1-\epsilon F_t$$

$M=\sum_t F_t$，于是 $W\le n(1-\epsilon F_1)\cdots\le n\mathrm{e}^{-\epsilon(F_1+\dots)}=n\mathrm{e}^{-\epsilon M}$。
同时 $W\ge(1-\epsilon)^m$。
$\therefore n\mathrm{e}^{-\epsilon M}\ge(1-\epsilon)^m$。整理即证。 □

我们将上面的算法严格化地表述。设 $w_i(t)$ 为 t 时刻专家 i 的权重，引入损失函数 l，$l_t(i)$ 为 t 时刻专家 i 的损失。

Algorithm 8 randomized weighted majority 算法（01 损失）

```
for t = 1, ..., T do
    选择 î_t ← w_i(t) / Σ_{j∈I} w_j(t)
    for i = 1, ..., n do
        计算损失 l_t(i)
        更新 w_i(t+1) = w_i(t)(1−ε)^{l_t(i)}
    end for
end for
```

如果损失函数是连续的，$l_t(i)\in[0,\rho]$，只用修改一下更新规则：

Algorithm 9 randomized weighted majority 算法（连续损失）

```
for t = 1, ..., T do
    选择 î_t ← w_i(t) / Σ_{j∈I} w_j(t)
    for i = 1, ..., n do
        计算损失 l_t(i)
        更新 w_i(t+1) = w_i(t)e^{−εl_t(i)}
    end for
end for
```

此时可以证明：

定理 3.3.4 设有 n 位专家，算法的期望犯错误次数为 M，而犯错误最少的专家的期望犯错次数为 m，上面的算法可以保证

$$M-m\le\frac{\ln n}{\epsilon}+T\epsilon$$

证明 证明被留做了作业题，关键还是总权重 ≥ 个人权重。 □

3.3.2 纳什均衡和 Minimax 定理

上述在线学习算法在博弈论中有神奇的应用，它可以给出一种构造性的收敛到纳什均衡的策略，从而证明 Minimax 定理：

定理 3.3.5 设 V 是零和博弈的 $n \times n$ 矩阵，有

$$\min_p \max_q p^\top V q = \max_q \min_p p^\top V q$$

证明 让玩家采取 randomized weighted majority 策略，对手每次采取 best response：

1. 初始每一行有权重 $w_1(i) = 1$。
2. 随机选择 $i_t \leftarrow \dfrac{w_t(i)}{\sum_j w_t(j)}$。
3. 对手采取最佳选择 $j_t = \arg\max_j V_{i_t,j}$。
4. 更新 $w_{t+1}(i) = w_t(i)\mathrm{e}^{-\epsilon V_{i\,j_t}}$。

上面的算法分析告诉我们：

$$\frac{1}{T}\sum_t p_t^\top V q_t \le \frac{1}{T}\min_p \sum_t p^\top V q_t + O\left(\frac{1}{\sqrt{T}}\right)$$

(为什么？$\sum p_t^\top V q_t - \min_p \sum p^\top V q_t \le \frac{\ln n}{\epsilon} + T\epsilon$。令 $\epsilon = \sqrt{\frac{\ln n}{T}}$, 则为 $O(\sqrt{T})$)。记 $\bar{q} = \frac{1}{T}\sum q_t$，则

$$\frac{1}{T}\min_p \sum_t p^\top V q_t = \min_p p^\top V \bar{q} \le \max_q \min_p p^\top V q$$

$$\therefore \frac{1}{T}\sum_t p_t^\top V q_t \le \max_q \min_p p^\top V q + O\left(\frac{1}{\sqrt{T}}\right)$$

同时，记 $\bar{p} = \frac{1}{T}\sum p_t$，由于 q_t 是 best response：

$$\frac{1}{T}\sum p_t^\top V q_t \ge \frac{1}{T}\max_q \sum_t p_t^\top V q = \max_q \bar{p}^\top V q \ge \min_p \max_q p^\top V q$$

最终

$$\min_p \max_q p^\top V q \le \max_q \min_p p^\top V q + O\left(\frac{1}{\sqrt{T}}\right)$$

而天然地有 $\min\max p^\top V q \ge \max\min p^\top V q$，令 $T \to \infty$ 即知 $\min\max p^\top V q = \max\min p^\top V q$ 成立。 □

3.3.3 在线学习的感知机算法

算法流程和之前相同。只是此时不保证数据线性可分。

定义 Hinge 损失：

$$L_{hinge}(w, x_t) = \begin{cases} 0, & \langle w, x_t \rangle y_t \geq 1 \\ 1 - \langle w, x_t \rangle y_t, & \text{o.w.} \end{cases}$$

定理 3.3.6 算法过程中犯错误次数不超过

$$\min_{w^*}(r^2\|w^*\|^2 + 2(L_{hinge}(w^*, x_1) + \cdots + L_{hinge}(w^*, x_T)))$$

其中 $r = \max_t \|x_t\|$。

证明 和之前的分析过程是完全类似的，变化的是

$$\langle w + y_t x_t, w^* \rangle - \langle w, w^* \rangle \geq 1 - L_{hinge}(w^*, x_t)$$

m 次更新后

$$\langle w, w^* \rangle \geq m - L_{hinge}(w, x_1) - \cdots - L_{hinge}(w, x_T)$$

同时和之前一样可以推出

$$\|w\| \leq r\sqrt{m} \Rightarrow \langle w, w^* \rangle \leq r\sqrt{m} \cdot \|w^*\|$$

于是

$$\sum L_{hinge} \geq m - r\sqrt{m}\|w^*\|$$

解此二次方程即可。 □

3.4 Boosting

Boosting 是一种把若干 weak learner “合成”较强的分类器的方式。所谓的 weak，指的是正确率 $\geq \frac{1}{2} + \gamma$，其中 γ 是很小的正数，也就是在数据上表现地只比乱猜略好一点。

假设有训练点 $x_1, \ldots, x_n$。

我们有一个 Oracle，能够从训练点和它们的权重中进行学习，返回一个 weak learner：

Input: 一个 $x_1, \ldots, x_n$ 上的分布 $\mathcal{D}$
Output: 一个 weak learner $h_{\mathcal{D}}$

待定一个常数 α，Boosting 的算法流程如下：

Algorithm 10 Boosting

```
w_1(i) = 1, ∀i
for t = 1, ..., T do
    h_t ← Oracle( ( w_t(i) / Σ w_t(j) )_i )
    for i = 1, ..., n do
        if h_t(i) ≠ y then
            w_{t+1}(i) = w_t(i) · α
        end if
    end for
end for
h = Majority(h_1, ..., h_T)
return h
```

定理 3.4.1 对 $\alpha = \frac{1+2\gamma}{1-2\gamma}$，上面的算法一定能在有限步内得到正确（在训练集上错误为 0）的 h。

证明 当 h 犯错时，至少 $\frac{T}{2}$ 的 weak learner 犯错。仍然利用总权重 $\geq$ 个人权重，

$$n\left(\left(\frac{1}{2}+\gamma\right)+\alpha\left(\frac{1}{2}-\gamma\right)\right)^T \geq \alpha^{T/2}$$

令 $\alpha = \frac{1+2\gamma}{1-2\gamma}$，则

$$\left(\frac{1+2\gamma}{1-2\gamma}\right)^{T/2} \leq n(1+2\gamma)^T$$

$$\Rightarrow (1-4\gamma^2)^{T/2} \geq \frac{1}{n}$$

$T \to +\infty$ 时不可能成立。 □

注：也可以从博弈的角度来看。矩阵每一行是 h_t。矩阵中的值为 $1[h_t(x_i) \neq y_i]$。weak learner 说明 $\forall q, \exists p, p^\top V q \leq \frac{1}{2} - \gamma$，故

$$\max_q \min_p p^\top V q \leq \frac{1}{2} - \gamma$$

由 Minimax 定理，

$$\min_p \max_q p^\top V q \leq \frac{1}{2} - \gamma$$

因此 $\exists p^*, \forall q, p^{*\top} V q \leq \frac{1}{2} - \gamma$。因而 $p^* V$ 的每个分量均应 $\leq \frac{1}{2} - \gamma$，故 p^* 是全对的。

第四章 流和采样算法

4.1 流算法（Streaming）

Streaming 指的大约是，我们需要一个算法对输入序列 $a_1, \ldots, a_n$ 给出输出，但是算法可利用的空间非常小，不能够读入全部的 a_i，只能保存非常少的信息，每次读入一个 a_i 然后丢弃。下面是一个简单的例子：

4.1.1 加权采样

给定 $a_1, \ldots, a_n$，要求最终以 $\frac{a_i}{\sum_j a_j}$ 的概率输出 a_i。

Algorithm 11

```
S = a_1, a = a_1
for i = 2, ..., n do
    以 a_i/(S + a_i) 的概率令 a ← a_i
    S ← S + a_i
end for
Output a
```

证明 归纳法。假设 t 时刻时 $\forall i \leq t$：

$$\Pr[a = a_i] = \frac{a_i}{S_t}$$

那么 $t+1$ 时刻，

$$\Pr[a = a_{t+1}] = \frac{a_{t+1}}{S_t + a_{t+1}} = \frac{a_{t+1}}{S_{t+1}}$$

对于 $i \le t$,

$$\Pr[a = a_i] = \frac{a_i}{S_t}\left(1 - \frac{a_{t+1}}{S_{t+1}}\right) = \frac{a_i}{S_t}\frac{S_t}{S_{t+1}} = \frac{a_i}{S_{t+1}}$$ □

4.1.2 最常出现的元素

设有 m 位候选人（从 1 到 m），a_i $(1 \le a_i \le m)$ 是对 m 位候选人的投票。若有人票数过半则输出该人；否则输出 0。

下面给出一个略弱化的算法（若有人票数过半则输出该人，否则输出任意一个人），这个算法只保证不会输出错误的人；想要确定结果的话还需要重新遍历一遍。

Algorithm 12 Majority Vote

```
a = a_1, cnt = 1
for i = 2, ..., n do
    if cnt == 0 then
        a = a_i, cnt = 1
    else
        if a == a_i then
            cnt++
        else
            cnt--
        end if
    end if
end for
return a
```

将算法想象成打擂台即可，很形象。

推论 4.1.1 若要求输出票数 $> \frac{n}{k+1}$ 的，那只用改成 k 个擂台即可。若已有擂台则该擂台 $cnt++$，若有空擂台则占，否则所有擂台 $cnt--$。

4.1.3 哈希与不同元素计数

输出 $a_1, \ldots, a_n$ 中不同元素的个数。

对于一个确定性算法，假设 $a_i \in \{1, \ldots, m\}$，那么算法显然至少需要 $O(m)$ 的空间。下面尝试给出一个非确定的算法来节省空间。首先，我们有如下的观察：

引理 4.1.2 设 $a_1, \ldots, a_k \sim \mathrm{Unif}([0,1])$，则

$$\mathbb{E}[\min\{a_1, \ldots, a_k\}] = \frac{1}{k+1}$$

证明 $\Pr[\min \le x] = 1 - (1-x)^k$，积分。 □

类似地，如果 $a_1, \ldots, a_k \sim \mathrm{Unif}(\{1, \ldots, m\})$，那么它的最小值的期望大约是 $\frac{m}{d+1}$，其中 $d = |\{a_1, \ldots, a_k\}|$。于是朴素的想法是，只维护最小值 min，最终输出 $\frac{m}{\min} - 1$。

显然，如果数据并不是均匀分布的，这个算法就会表现得不太好，接下来采取的办法是使用哈希函数来尽可能地把原数据映射地均匀。

取大素数 $M > m$，再任取 $a, b \in \{0, \ldots, M-1\}$，定义 $h_{ab}(x) = ax + b \mod M$。这样定义的哈希函数有很好的性质：

引理 4.1.3 对于随机的 a, b，若 $x_1 \neq x_2$，那 $h_{ab}(x_1)$ 和 $h_{ab}(x_2)$ 是独立的。i.e.

$$\Pr[h(x_1) = y_1 \wedge h(x_2) = y_2] = \Pr[h(x_1) = y_1] \cdot \Pr[h(x_2) = y_2]$$

证明

$$h(x_i) = y_i \iff ax_i + b \equiv y_i \pmod M$$

$$\begin{cases} ax_1 + b \equiv y_1 \pmod M \\ ax_2 + b \equiv y_2 \pmod M \end{cases}$$

依中国剩余定理（实际上是线性方程组），方程组有唯一解 a^*, b^*。

$$\begin{aligned} \Pr[h(x_1) = y_1 \wedge h(x_2) = y_2] &= \Pr[a = a^*, b = b^*] \\ &= \Pr[a = a^*] \cdot \Pr[b = b^*] \\ &= \frac{1}{M^2} \\ &= \Pr[h(x_1) = y_1] \cdot \Pr[h(x_2) = y_2] \end{aligned}$$ □

定理 4.1.4 设 $\{b_1, \ldots, b_d\}$ 为 $a_1, \ldots, a_n$ 中互不相同的元素。随机某个 $h \in \{h_{ab}\}$，记 $\min = \min\{h(b_1), \ldots, h(b_d)\}$。那么至少有 $\frac{2}{3} - \frac{d}{M}$ 的概率使得

$$\frac{d}{6} \leq \frac{M}{\min} \leq 6d$$

证明 $\frac{d}{6} \leq \frac{M}{\min} \leq 6d \iff \frac{M}{6d} \leq \min \leq \frac{6M}{d}$。

先考虑左半边，是简单的 Union Bound：

$$\begin{aligned} \Pr\left[\min \leq \frac{M}{6d}\right] &= \Pr\left[\exists k, h(b_k) \leq \frac{M}{6d}\right] \\ &\leq d \cdot \frac{1}{M} \cdot \left\lceil \frac{M}{6d} \right\rceil \quad \left(\approx d \cdot \frac{1}{6d} = \frac{1}{6}\right) \\ &\leq d\left(\frac{1}{6d} + \frac{1}{M}\right) \\ &= \frac{1}{6} + \frac{d}{M} \end{aligned}$$

再考虑右半边：

$$\Pr\left[\min \geq \frac{6M}{d}\right] = \Pr\left[\forall k, h(b_k) \geq \frac{6M}{d}\right]$$

令 $Y := \sum Y_k$，其中

$$Y_k := \begin{cases} 1 & o.w. \\ 0 & h(b_k) > \frac{6M}{d} \end{cases}$$

$$\begin{aligned}
\Pr\left[\forall k, h(b_k) \geq \frac{6M}{d}\right] &= \Pr[Y = 0] \\
&\leq \Pr[|Y - \mathbb{E}[Y]| \geq \mathbb{E}[Y]] \\
&\leq \frac{\mathrm{Var}(Y)}{\mathbb{E}[Y]^2} = \frac{d \cdot \mathrm{Var}(Y_1)}{d^2 \mathbb{E}[Y_1]^2} \\
&= \frac{1}{d} \frac{\mathbb{E}[Y_1^2] - \mathbb{E}[Y_1]^2}{\mathbb{E}[Y_1]^2} \leq \frac{1}{d} \frac{\mathbb{E}[Y_1]}{\mathbb{E}[Y_1]^2} \\
&= \frac{1}{d\mathbb{E}[Y_1]} \leq \frac{1}{6}
\end{aligned}$$

最终

$$\Pr\left[\min < \frac{M}{6d} \vee \min > \frac{6M}{d}\right] \leq \frac{1}{6} + \frac{1}{6} + \frac{d}{M} = \frac{1}{3} + \frac{d}{M} \qquad \square$$

4.1.4 频数的二阶矩

我们关心 $a_1, \ldots, a_n$ 的 “unbalanced” 程度。设 f_s 为 s 出现的次数，估计 $\sum f_s^2$。

Algorithm 13

```
Alg. 随机一个哈希函数 h : {1, ..., m} → {−1, 1}。
Sum = 0
for i = 1, ..., n do
    Sum+ = h(a_i)
end for
return Sum^2
```

定理 4.1.5 如果 h 同之前一样是“两两独立”的，上述算法最终能给出 $\sum f_s^2$ 的无偏估计。

证明 算法最后实际输出了 $(\sum h(s)f_s)^2$。

$$\begin{aligned}\mathbb{E}\left[\left(\sum h(s)f_s\right)^2\right] &= \mathbb{E}\left[\sum_{s,s'} h(s)h(s')f_s f_{s'}\right] \\ &= \mathbb{E}\left[\sum_s f_s^2\right] + \mathbb{E}\left[\sum_{s\neq s'} h(s)h(s')f_s f_{s'}\right] \\ &= \sum_s f_s^2\end{aligned}$$

(因为对于 $s \neq s'$，$\mathbb{E}[h(s)h(s')] = \mathbb{E}[h(s)]\mathbb{E}[h(s')] = 0$)。 □

如果要分析这个算法的好坏，那么就需要计算方差；此时“两两独立”就不太够了，需要“四四独立”。此处略去。

4.2 矩阵采样

4.2.1 Sampling

本节的目标是对两个矩阵 A 和 B 进行采样，尽可能地去近似乘积 AB。令 a_k 为 A 的列向量，$b_k^\top$ 为 B 的行向量，

$$AB = \sum_k a_k b_k^\top$$

我们希望对 $1, \ldots, n$ 赋予权重 $\Pr[k = i] = p_i$，采样一个 $k \leftarrow \{1, \ldots, n\}$，然后计算

$$X = \frac{1}{p_k} a_k b_k^\top$$

此时的 X 已经是 AB 的一个无偏估计：

$$\mathbb{E}[X] = \sum p_k \cdot \frac{1}{p_k} a_k b_k^\top = AB$$

问题是，怎样取 p_k 能够让 $\mathbb{E}[\|X - AB\|_F^2]$ 最小？首先，有如下观察：

$$\begin{aligned}\mathbb{E}[\|X - AB\|_F^2] &= \mathbb{E}\left[\sum_{ij}(X_{ij} - \mathbb{E}[X_{ij}])^2\right] \\ &= \sum_{ij} \mathrm{Var}(X_{ij})\end{aligned}$$

$$
\begin{aligned}
&= \sum_{ij}(\mathbb{E}[X_{ij}^2] - \mathbb{E}[X_{ij}]^2) \\
&= \mathbb{E}[\|X\|_F^2] - \|AB\|_F^2
\end{aligned}
$$

所以只需要最小化 $\mathbb{E}[\|X\|_F^2]$。而

$$
\mathbb{E}[\|X\|_F^2] = \sum_k p_k \frac{1}{p_k^2}\|a_k b_k^\top\|_F^2 = \sum_k \frac{1}{p_k}\|a_k\|^2\|b_k\|^2
$$

由 Cauchy 不等式，最好的做法正是 $p_k \propto \|a_k\|\|b_k\|$。
当 $B = A^\top$ 时，$p_k \propto \|a_k\|^2$，即 $p_k = \frac{\|a_k\|^2}{\|A\|_F^2}$。
即使 $B \neq A^\top$ ，为了上界的简洁依然可以如上取 p_k。此时

$$
\mathbb{E}[\|X - AB\|_F^2] \leq \|A\|_F^2\|B\|_F^2
$$

采取多次采样可以进一步降低上界。设 s 次采样得到 $X_1, \ldots, X_s$，取 $X = \frac{1}{s}\sum X_i$。那么就有

$$
\mathbb{E}[\|X - AB\|_F^2] \leq \frac{1}{s}\|A\|_F^2\|B\|_F^2
$$

4.2.2 Sketching

这一节和上一节是延续的，我们希望给出一个矩阵 A 的 Sketch（最“好”的方式当然是 SVD，但 SVD 所需的时间、空间较大）。利用上一节的方法，我们可以令 $B = I$ 然后去 sample X 使

$$
\mathbb{E}[\|X - A\|_F^2] \leq \frac{n\|A\|_F^2}{s}
$$

但这个 Bound 不是太好。

为此，先对 A 进行行采样（采样 r 次，第 k 行的概率 $p_k \propto \|a_k\|^2$）得到矩阵 R，这个过程等同于在之前的 Sampling 方法中取 AB 为 $A^\top A$，得到 $X = R^\top R$ 且

$$
\mathbb{E}[\|A^\top A - R^\top R\|_F^2] \leq \frac{\|A\|_F^4}{r}
$$

下面，尝试找一个“投影矩阵” P，s.t.

1. $\forall y, PR^\top y = R^\top y$
2. $\forall x, \forall y, x^\top R^\top y = 0 \implies Px = 0$

实际上是说，P 在 R 的行向量空间上表现为单位矩阵，在其正交补空间上表现为 0，其实是一种广义逆。我们直接断言 P 是存在的：

1. 若 R 可逆，则 $P = R^\top(RR^\top)^{-1}R$

2. 若 R 不可逆，则 $P = \sum \sigma_i^{-1} u_i u_i^\top$（相当于在 SVD 中对对角线上的非零元取倒数）

这样的 P 能使 $A \approx AP$。先引入 2-范数

$$\|A - AP\|_2^2 = \max_{\|v\|=1} \|(A - AP)v\|^2$$

以 V 记 R 的行向量空间。对 $v \in V$，$Pv = v \implies (A - AP)v = Av - Av = 0$。所以只用考虑 $v \in V^\perp$ 的那些，此时 $Rv = 0$ 且 $Pv = 0$。

$$\begin{aligned}
\|(A - AP)v\|_2^2 &= \|Av\|_2^2 \\
&= v^T A^T A v \\
&= v^T (A^T A - R^T R) v \quad (\text{因} Rv = 0) \\
&\le \|A^T A - R^T R\|_2 \\
&\le \|A^T A - R^T R\|_F
\end{aligned}$$

(中间用到了 $\|x\| = 1$ 时 $x^T A x \le \|A\|_2 \le \|A\|_F$)

此时

$$\mathbb{E}[\|A - AP\|_2^2] \le \mathbb{E}[\|A^T A - R^T R\|_F] \le \sqrt{\frac{\|A\|_F^4}{r}} = \frac{\|A\|_F^2}{\sqrt{r}}$$

现在对 AP 使用上一节的采样算法得到 X：

$$\mathbb{E}[\|X - AP\|_F^2] \le \frac{\|A\|_F^2 \|P\|_F^2}{s} \le \frac{r}{s} \|A\|_F^2$$

(P 在 V 上为 1，在 $V^\perp$ 为 0，故 $\|P\|_F^2 = \operatorname{rank}(R) \le r$)

最终（用 $a^2 \le (b + c)^2 = b^2 + c^2 + 2bc \le 2b^2 + 2c^2$）

$$\begin{aligned}
\|X - A\|_2^2 &\le 2\|X - AP\|_2^2 + 2\|AP - A\|_2^2 \\
&\le \|A\|_F^2 \left(\frac{2}{\sqrt{r}} + \frac{2r}{s} \right)
\end{aligned}$$

取 $r = s^{\frac{2}{3}}$ 可以使之最小。

第五章 随机图

5.1 “相变”

用记号 $G_{n,p}$ 表示有 n 个顶点，每对顶点间有 p 的概率连边的随机图。随机图中有一种比较有意思的现象，例如，我们关注 $G_{n,p}$ 中是否存在 K_3（三角形）的概率。当 $p=0$ 时，这个概率显然为 0，而 $p=1$ 时概率显然为 1。而当 n 充分大时，这个概率会在“阈值” $p^*(n)=\frac{1}{n}$ 处发生突跃：

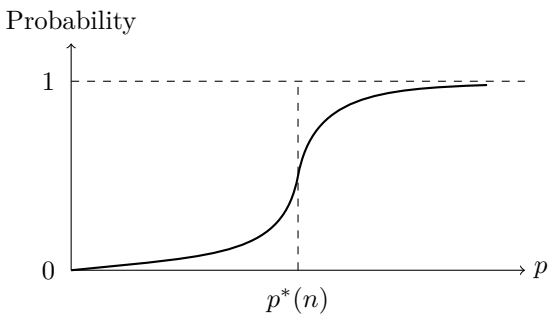

图 5–1: threshold

命题 5.1.1

$$\lim_{n\to\infty}\Pr[\triangle\in G_{n,p}]=0\ ,\ 若\quad p(n)=o\left(\frac{1}{n}\right)$$
$$\lim_{n\to\infty}\Pr[\triangle\in G_{n,p}]=1\ ,\ 若\quad p(n)=\omega\left(\frac{1}{n}\right)$$

证明 设 X 为三角形的数量。那么

$$\mathbb{E}[X] = \binom{n}{3} \cdot p^3 \approx (np)^3$$

这里就能看出为什么存在阈值 $\frac{1}{n}$。

Case 1: 当 $p \ll \frac{1}{n}$ 时，$np \to 0$。简单使用 Markov Bound：

$$\begin{aligned}\Pr[\text{存在}\triangle] &= \Pr[X \geq 1] \\ &\leq \mathbb{E}[X] \to 0\end{aligned}$$

Case 2: 当 $p \gg \frac{1}{n}$ 时，$np \to \infty$。我们希望证明利用 Chebyshev Bound 来证明 $\Pr[\text{不存在}\triangle] \to 0$。

$$\begin{aligned}\Pr[\text{不存在}\triangle] &= \Pr[X = 0] \\ &\leq \Pr[|X - \mathbb{E}[X]| \geq \mathbb{E}[X]] \\ &\leq \frac{\mathrm{Var}(X)}{\mathbb{E}[X]^2}\end{aligned}$$

定义指示变量

$$I_{ijk} = \begin{cases} 1 & i, j, k \text{ 构成三角形} \\ 0 & \text{o.w.} \end{cases}$$

则 $X = \sum I_{ijk}$。

若两个三角形不共用边，那么它们是独立的；只有共用边的情况不独立：

图 5–2: 三种位置关系

这种情况下涉及 4 个点，5 条边。

$$\begin{aligned}\mathbb{E}[I_{ijk} I_{i'j'k'}] &= p^5 \\ \mathrm{Cov}(I_{ijk}, I_{i'j'k'}) &= p^5 - p^3 \cdot p^3 \approx p^5\end{aligned}$$

而这样的形状有 $\binom{n}{4}$ 个，所以

$$\mathrm{Var}(X) = \sum \mathrm{Var}(I_{ijk}) + \sum \mathrm{Cov}(I_{ijk}, I_{i'j'k'})$$

$$
\begin{aligned}
&\approx \binom{n}{3} \cdot p^3 + \binom{n}{4} \cdot p^5 \\
&\approx (np)^3 + n^4 p^5
\end{aligned}
$$

计算比值：

$$
\begin{aligned}
\frac{\mathrm{Var}(X)}{\mathbb{E}[X]^2} &\approx \frac{(np)^3 + n^4 p^5}{(np)^6} \\
&= \frac{1}{(np)^3} + \frac{1}{n^2 p} \to 0
\end{aligned}
$$

$\therefore \Pr[X = 0] \to 0$。即 $\Pr[\text{存在三角形}] \to 1$。 □

作业题中存在更多的例子，比如 $G_{n,p}$ 中存在孤立点的概率（成为了期末考试题），图是二部图的概率，图中存在 K_4 的概率（隔壁离散的期末题，那边介绍的更严谨，还有 sharp threshold 和 super sharp threshold 等）。